

《数值计算方法》总复习

王志明

wangzhiming@ies.ustb.edu.cn

考核方式

- 平时作业与实验：20%(作业、实验报告);
- 期末考试：80%，闭卷。


课件下载地址：

- 地址：<http://email.163.com>
- 邮箱：nm_ustb@163.com
- 密码：2015_nm

第一章 绪论

- 1.1 数值计算方法及其主要内容
- 1.2 误差的来源
- 1.3 绝对误差、相对误差及有效数字
- 1.4 数值计算中误差的传播
- 1.5 数值计算中应注意的问题

§ 1.2 误差的来源



- 模型误差
- 观测误差
- 截断误差
- 舍入误差

§ 1.3 绝对误差、相对误差及有效数字

§ 1.3.1 绝对误差

定义1.2 设 x^* 为准确值 x 的一个近似值，则

$$e(x^*) = x - x^*$$

称为近似值 x^* 的绝对误差，简称为误差。

误差限：

$$|e(x^*)| = |x - x^*| \leq \varepsilon$$

§ 1.3.2 相对误差

定义1.3 设 x^* 为准确值 x 的一个近似值，则绝对误差与准确值之比称为近似值 x^* 的**相对误差**：

$$e_r(x^*) = \frac{e(x^*)}{x} = \frac{x - x^*}{x}$$

近似：

$$|e_r(x^*)| \approx \left| \frac{e(x^*)}{x^*} \right|$$

相对误差限：

$$|e_r(x^*)| = \left| \frac{e(x^*)}{x^*} \right| \leq \varepsilon_r$$

有效数字：从第一个非零数字到(小数点后)最后一位的所有数字。

定理1.1 若 x 的近似值：

$$x^* = \pm 0.a_1 a_2 \cdots a_n \times 10^m (a_1 \neq 0)$$

有 n 位有效数字，则 $\frac{1}{2a_1} \times 10^{-n+1}$ 为其相对误差限。

反之，若 x^* 的相对误差限满足

$$\varepsilon_r \leq \frac{1}{2(a_1 + 1)} \times 10^{-n+1}$$

则 x^* 至少有 n 位有效数字。

§ 1.4 数值计算中误差的传播

§ 1.4.1 基本运算误差中误差估计

给定多元函数： $y = f(x_1, x_2, \dots, x_n)$

近似值为： $y^* = f(x_1^*, x_2^*, \dots, x_n^*)$

y 所产生的误差可以用Taylor展开式来估计：

$$e(y) = y - y^* = f(x_1, x_2, \dots, x_n) - f(x_1^*, x_2^*, \dots, x_n^*)$$

$$\approx df(x_1^*, \dots, x_n^*) = \sum_{i=1}^n \frac{\partial}{\partial x_i} f(x_1, \dots, x_n) \cdot (x_i - x_i^*)$$

$$= \sum_{i=1}^n \frac{\partial}{\partial x_i} f(x_1, \dots, x_n) \cdot e(x_i^*)$$

相对误差:

$$\boxed{e_r(y^*)} = \frac{e(y^*)}{y} \approx \sum_{i=1}^n \frac{\partial f}{\partial x_i} \cdot \frac{e(x_i^*)}{y^*}$$
$$= \sum_{i=1}^n \frac{\partial f}{\partial x_i} \cdot \frac{x_i^*}{y^*} \boxed{e_r(x_i^*)}$$

也可写为:

$$e_r(y^*) = \frac{e(y^*)}{y^*} \approx \frac{df(x_1^*, \dots, x_n^*)}{f(x_1^*, \dots, x_n^*)} = d(\ln f)$$

和、差、积、商误差公式：

$$\begin{cases} e(x_1 \pm x_2) = e(x_1) \pm e(x_2) \\ e_r(x_1 \pm x_2) = \frac{x_1}{x_1 \pm x_2} e_r(x_1) \pm \frac{x_2}{x_1 \pm x_2} e_r(x_2) \end{cases}$$

$$\begin{cases} e(x_1 x_2) \approx x_2 e(x_1) + x_1 e(x_2) \\ e_r(x_1 x_2) \approx e_r(x_1) + e_r(x_2) \end{cases}$$

$$\begin{cases} e\left(\frac{x_1}{x_2}\right) \approx \frac{1}{x_2} e(x_1) - \frac{x_1}{x_2^2} e(x_2) \\ e_r\left(\frac{x_1}{x_2}\right) \approx e_r(x_1) - e_r(x_2) \end{cases}$$

基本要求

- 有效位数概念
- 误差基本概念
- 误差传递的计算

第三章 非线性方程的解法

- 3.1 二分法
- 3.2 简单迭代法
- 3.3 牛顿迭代法
- 3.4 牛顿迭代法的变形

§ 3.1 二分法

若 $f(x)$ 在 $[a, b]$ 上连续,
且 $f(a)f(b) < 0$

(1) 取 $x_0 = \frac{a+b}{2}$, 计算 $f(x_0)$

若 $f(a)f(x_0) < 0$, 则根位于 $[a, x_0]$

取 $a_1 = a, b_1 = x_0$

若 $f(a)f(x_0) > 0$, 则根位于 $[x_0, b]$

取 $a_1 = x_0, b_1 = b$

(2) 取 $x_1 = \frac{a_1 + b_1}{2}$, 计算 $f(x_1)$

.....

$$[a_0, b_0] \supset [a_1, b_1] \supset \cdots \supset [a_n, b_n] \cdots$$




图 3-1 二分法示意图

$$[a_n, b_n] \text{长度为: } b_n - a_n = \frac{b_{n-1} - a_{n-1}}{2} = \dots = \frac{b - a}{2^n}$$

以 $x_n = \frac{b_n + a_n}{2}$ 以近似解，误差满足：

$$|\alpha - x_n| \leq \frac{b_n - a_n}{2} = \frac{b - a}{2^{n+1}}$$

若设定误差不大于 ε

$$\text{则 } |\alpha - x_n| \leq \frac{b - a}{2^{n+1}} < \varepsilon$$

$$2^{n+1} > \frac{b - a}{\varepsilon}$$

则可估计所需迭代次数：

$$n + 1 \geq \lceil (\ln(b - a) - \ln \varepsilon) / \ln 2 \rceil$$

$$[a_n, b_n] \text{长度为: } b_n - a_n = \frac{b_{n-1} - a_{n-1}}{2} = \dots = \frac{b - a}{2^n}$$

以 $x_n = \frac{b_n + a_n}{2}$ 以近似解，误差满足：

$$|\alpha - x_n| \leq \frac{b_n - a_n}{2} = \frac{b - a}{2^{n+1}}$$

若设定误差不大于 ε

$$\text{则 } |\alpha - x_n| \leq \frac{b - a}{2^{n+1}} < \varepsilon$$

$$2^{n+1} > \frac{b - a}{\varepsilon}$$

则可估计所需迭代次数：

$$n + 1 \geq \lceil (\ln(b - a) - \ln \varepsilon) / \ln 2 \rceil$$

$$n \geq \log_2(b - a) - \log_2 \varepsilon - 1$$

§ 3.2 简单迭代法

- 将方程 $f(x)=0$ 化为另一个与它同解的方程:

$$x = \varphi(x)$$

- 取初值 x_0 代入右边得到:

$$x_1 = \varphi(x_0)$$

- 如果迭代收敛, 则结果为所求根。

定理 3.1 设迭代函数满足:

(1) 当 $x \in [a, b]$ 时, $a \leq \varphi(x) \leq b$

(2) 存在 $0 < L < 1$, 对任意 $x \in [a, b]$ 有 $|\varphi'(x)| \leq L$

则存在唯一根, 对任意 初值 $x_0 \in [a, b]$ 收敛于 α ,

且

$$\begin{aligned} |x_k - \alpha| &\leq \frac{L}{1-L} |x_k - x_{k-1}| \\ |x_k - \alpha| &\leq \frac{L^k}{1-L} |x_1 - x_0| \end{aligned}$$

判断是否收敛后，收敛速度如何度量？

设迭代格式为 $x_{k+1} = \varphi(x_k)$ ，当 $k \rightarrow \infty$ 时， $x_k \rightarrow \alpha$ ，
并记 $e_k = x_k - \alpha$ 。

定义**3.1** 若存在实数 $p \geq 1$ 和 $c > 0$ 满足：

$$\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{|e_k|^p} = c$$

则称迭代法为 p 阶收敛。

$p = 1$ 为线性收敛， $p > 1$ 为超线性收敛，
 $p = 2$ 为平方收敛。

定理 3.3 若迭代函数 $\varphi(x)$ 在根 α 附近满足：

(1) $\varphi(x)$ 存在 p 阶导数且连续；

(2) $\varphi'(\alpha) = \varphi''(\alpha) = \dots = \varphi^{(p-1)}(\alpha) = 0, \quad \varphi^{(p)}(\alpha) \neq 0$

则 $x_{k+1} = \varphi(x_k)$ 为 p 阶收敛。

§ 3.3 牛顿迭代法

牛顿迭代法又称为切线法。

设 x_k 是 $f(x) = 0$ 根 α 附近的近似值，
过 $(x_k, f(x_k))$ 作切线：

$$L_k(x) = f(x_k) + f'(x_k)(x - x_k)$$

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$




图 3-2 Newton 迭代法几何意义

当 $f'(\alpha) \neq 0$ 时， $\varphi'(\alpha) = 0$ ，至少平方收敛。

定理3.4 设 $f(\alpha) = 0, f'(\alpha) \neq 0$, 且 $f(x)$ 在 α 的邻域内具有二阶连续导数, 则 如下牛顿法产生的迭代 序列

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

局部收敛到 α , 且收敛阶数至少为 2,
当 $f''(\alpha) \neq 0$ 时, 收敛阶恰为 2。

§ 3.4 牛顿迭代法的变形

§ 3.4.1 简化的牛顿迭代公式

应用牛顿迭代公式, 每一步需要计算 $f'(x_n)$.

为了避免计算导数值, 将

$$x_{k+1} = x_k - f(x_k) / f'(x_k)$$

修改为:

$$x_{k+1} = x_k - f(x_k) / f'(x_0)$$




图 3-6 迭代平行

可进一步简化为： $x_{k+1} = x_k - f(x_k)/c$

迭代公式为： $\varphi(x) = x - \frac{f(x)}{c}$

根据收敛条件 $|\varphi'(x)| \leq L < 1$ 可得：

$$\varphi'(x) = 1 - \frac{f'(x)}{c}$$

$$0 < \frac{f'(x)}{c} < 2$$

§ 3.4.2 弦截法

为了避免计算导数值，用下式近似导数：

$$f'(x_k) \approx \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$$

迭代公式为：

$$x_{k+1} = x_k - \frac{f(x_k)}{f(x_k) - f(x_{k-1})} (x_k - x_{k-1})$$

以直代曲，需要两点函数值开始迭代。

§ 3.4.3 牛顿下山法

为了防止迭代发散，附加条件：

$$|f(x_{k+1})| < |f(x_k)|$$

引入 $0 < \lambda \leq 1$

$$x_{k+1} = x_k - \lambda \frac{f(x_k)}{f'(x_k)}$$

λ 为下山因子，取不同值进行试探：

$$\lambda = 1, \frac{1}{2}, \frac{1}{2^2}, \dots$$

基本要求

- 二分法及其迭代次数估计；
- 简单迭代法及其收敛性判断；
- 牛顿法；
- 简化牛顿法、弦截法、牛顿法下山法。

第四章 线性方程组的解法

- 4.1 向量范数和矩阵范数
- 4.2 迭代法
- 4.3 高斯消去法
- 4.4 高斯列主元消去法
- 4.5 三角分解法

§ 4.1 向量范数和矩阵范数

向量**范数**是欧氏空间向量**长度**的推广，向量和矩阵的范数是用来衡量向量和矩阵大小的度量。

§ 4.4.1 向量的范数

定义4.1 R^n 上范数是一个非负实数值，记作 $\|\cdot\|$ ，满足：

(1) $\|x\| \geq 0$, $\forall x \in R^n$; 当且仅当 $x = 0$ 时, $\|x\| = 0$ **非负**

(2) 对任何 $\alpha \in R$, $x \in R^n$, $\|\alpha x\| = |\alpha| \cdot \|x\|$ **正齐次**

(3) $\|x + y\| \leq \|x\| + \|y\|$, $\forall x, y \in R^n$ **三角不等式**

设有向量 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ ，常见向量范数包括：

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$$

$$\|\mathbf{x}\|_2 = \left(\sum_{i=1}^n |x_i|^2 \right)^{\frac{1}{2}} = (\mathbf{x}, \mathbf{x})^{\frac{1}{2}} = (\mathbf{x}^T \mathbf{x})^{\frac{1}{2}}$$

$$\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} \{|x_i|\}$$

统一形式：

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

§ 4.1.2 矩阵的范数

定义4.2 称定义在 $R^{n \times n}$ 上的实数函数 $\|\cdot\|$ 为**矩阵范数**,

如果对 $R^{n \times n}$ 中的任意矩阵**A**和**B**, 满足:

$$(1) \|\mathbf{A}\| \geq 0, \text{当且仅当} \mathbf{A} = \mathbf{0} \text{时}, \|\mathbf{A}\| = 0$$

非负

$$(2) \text{对任一数} k \in R, \text{有} \|k\mathbf{A}\| = |k| \|\mathbf{A}\|$$

正齐次

$$(3) \|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$$

三角不等式

$$(4) \|\mathbf{AB}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{B}\|$$

相容性

定义4.3 对于给定的范数 $\|\cdot\|$ ，如果对任意 $\mathbf{A} \in R^{n \times n}$

满足：
$$\|\mathbf{A}\mathbf{x}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\|$$

称矩阵范数与向量范数是**相容**的。

定理4.2 设在 R^n 中给定一种向量范数，对任一矩阵 \mathbf{A} ，下式定义了一种矩阵范数，且与所给的向量范数相容：

$$\|\mathbf{A}\| = \max_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|$$

定理4.3 设 $\mathbf{A} = (a_{ij}) \in R^{n \times n}$, 则

$$\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \left[\sum_{i=1}^n |a_{ij}| \right]$$

$$\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}$$

$$\|\mathbf{A}\|_{\infty} = \max_{1 \leq i \leq n} \left[\sum_{j=1}^n |a_{ij}| \right]$$

$\lambda_{\max}(\mathbf{A}^T \mathbf{A})$ 为矩阵 $\mathbf{A}^T \mathbf{A}$ 的最大特征值

§ 4.1.3 误差分析

定义4.4 如果线性方程组 $Ax=b$ 中， A 或 b 的微小变化，就会引起方程组解的巨大变化，称为病态方程组，否则称为良态方程组。对应矩阵称为病态或良态矩阵。

定义4.5 设 A 为非奇异矩阵， $\|\cdot\|$ 为范数，条件数为：

$$\text{cond}(A) = \|A\| \|A^{-1}\|$$

条件数大的矩阵为病态矩阵。条件数不小于**1**:

$$\|\mathbf{A}\| \|\mathbf{A}^{-1}\| \geq \|\mathbf{A}\mathbf{A}^{-1}\| = 1$$

常用条件数:

$$(1) \text{cond}(\mathbf{A})_{\infty} = \|\mathbf{A}\|_{\infty} \|\mathbf{A}^{-1}\|_{\infty}$$

$$(2) \text{cond}(\mathbf{A})_2 = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2 = \sqrt{\frac{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}{\lambda_{\min}(\mathbf{A}^T \mathbf{A})}}$$

§ 4.2 迭代法

[illegible]

设**A**为非奇异矩阵，迭代法求解的基本思路：

首先将线性方程组 $\mathbf{Ax} = \mathbf{b}$ 化为一个适合迭代的

等价方程组: $\mathbf{x} = \mathbf{G}\mathbf{x} + \mathbf{d}$

比如 $A=M-N$ ，原式为 $Mx=Nx+b$ ，当 M 为非奇异时：

$$\mathbf{x} = \mathbf{M}^{-1}\mathbf{N}\mathbf{x} + \mathbf{M}^{-1}\mathbf{b}, \quad \text{即 } \mathbf{G} = \mathbf{M}^{-1}\mathbf{N}, \mathbf{d} = \mathbf{M}^{-1}\mathbf{b}$$

取任意初始向量 $\mathbf{x}^{(0)}$ 构成迭代序列：

$$\mathbf{x}^{(k+1)} = \mathbf{G}\mathbf{x}^{(k)} + \mathbf{d} \quad (k = 0, 1, \dots)$$

其中 \mathbf{G} 称为迭代矩阵。

§ 4.2.1 雅克比(Jacobi)迭代法

设 \mathbf{A} 为非奇异矩阵且 $a_{ii} \neq 0 (i = 1, 2, \dots, n)$

[illegible]

可改写为

[illegible]

记: $\mathbf{D} = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$

$$\mathbf{L} = \begin{bmatrix} 0 & 0 & \dots & 0 \\ a_{21} & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & 0 \end{bmatrix}, \mathbf{U} = \begin{bmatrix} 0 & a_{12} & \dots & a_{1n} \\ 0 & 0 & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{bmatrix}$$

则: $\mathbf{A} = \mathbf{D} + \mathbf{L} + \mathbf{U}$

$$\mathbf{x} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x} + \mathbf{D}^{-1}\mathbf{b}$$

记: $\mathbf{B} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}), \quad \mathbf{d} = \mathbf{D}^{-1}\mathbf{b}$

则: $\mathbf{x} = \mathbf{B}\mathbf{x} + \mathbf{d}$

迭代形式: $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{d}, \quad k = 0, 1, \dots$

§ 4.2.2 高斯-赛德尔(Gauss-Seidel)迭代法

$$\mathbf{A} = \mathbf{D} + \mathbf{L} + \mathbf{U}$$

取： $\mathbf{M} = \mathbf{D} + \mathbf{L}, \mathbf{N} = -\mathbf{U}$

$$\mathbf{x} = -(\mathbf{D} + \mathbf{L})^{-1} \mathbf{U} \mathbf{x} + (\mathbf{D} + \mathbf{L})^{-1} \mathbf{b}$$

迭代公式： $\mathbf{x}^{(k+1)} = -(\mathbf{D} + \mathbf{L})^{-1} \mathbf{U} \mathbf{x}^{(k)} + (\mathbf{D} + \mathbf{L})^{-1} \mathbf{b}$

为避免 $(\mathbf{D} + \mathbf{L})^{-1}$ ，改写为：

$$(\mathbf{D} + \mathbf{L}) \mathbf{x}^{(k+1)} = -\mathbf{U} \mathbf{x}^{(k)} + \mathbf{b}$$

$$\mathbf{D} \mathbf{x}^{(k+1)} = -\mathbf{L} \mathbf{x}^{(k+1)} - \mathbf{U} \mathbf{x}^{(k)} + \mathbf{b}$$

$$\mathbf{x}^{(k+1)} = -\mathbf{D}^{-1} \mathbf{L} \mathbf{x}^{(k+1)} - \mathbf{D}^{-1} \mathbf{U} \mathbf{x}^{(k)} + \mathbf{D}^{-1} \mathbf{b}$$

$$\begin{cases} x_1^{(k+1)} = 1/a_{11}(-a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)} + b_1) \\ x_2^{(k+1)} = 1/a_{22}(-a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)} + b_2) \\ \vdots \\ x_n^{(k+1)} = 1/a_{nn}(-a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \dots - a_{n,n-1}x_{n-1}^{(k+1)} + b_n) \end{cases}$$

$$\begin{aligned} x_i^{(k+1)} &= 1/a_{ii} \left(-\sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} + b_i \right) \\ &= x_i^{(k)} + 1/a_{ii} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i}^n a_{ij}x_j^{(k)} \right) \end{aligned}$$

§ 4.2.3 迭代法的收敛性

设迭代格式: $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$

精确解为: $\mathbf{x}^* = \mathbf{B}\mathbf{x}^* + \mathbf{f}$

相减得到: $\mathbf{x}^{(k+1)} - \mathbf{x}^* = \mathbf{B}\mathbf{x}^{(k)} - \mathbf{B}\mathbf{x}^* = \mathbf{B}(\mathbf{x}^{(k)} - \mathbf{x}^*)$

令: $\mathbf{x}^{(k+1)} - \mathbf{x}^* = \boldsymbol{\varepsilon}^{(k+1)}, \mathbf{x}^{(k)} - \mathbf{x}^* = \boldsymbol{\varepsilon}^{(k)}, \dots, \mathbf{x}^{(0)} - \mathbf{x}^* = \boldsymbol{\varepsilon}^{(0)}$

$$\mathbf{x}^{(k+1)} - \mathbf{x}^* = \mathbf{B}^{k+1} \boldsymbol{\varepsilon}^{(0)}$$

如果要求 $k \rightarrow \infty$ 时 $\boldsymbol{\varepsilon}^{(k+1)} \rightarrow 0$, 只有 $\mathbf{B}^{k+1} \rightarrow 0$

定理4.5 $\lim_{k \rightarrow \infty} \boldsymbol{\varepsilon}^{(k)} = 0$ (即 $\mathbf{x}_i^{(k)} \rightarrow \mathbf{x}_i^*$) 的充分必要条件是

当 $k \rightarrow \infty$ 时, $B^k \rightarrow 0$

谱半径： $\rho(\mathbf{B}) = \max(|\lambda_i|), i = 1, 2, \dots, n$
 λ_i 为矩阵 \mathbf{B} 的特征值

定理4.6 迭代 $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$ 对任意 $\mathbf{x}^{(0)}$ 和 \mathbf{f} 收敛的充分必要条件是 $\rho(\mathbf{B}) < 1$ 。

根据特征值定义： $\mathbf{B}\mathbf{x} = \lambda\mathbf{x}$

$$\|\lambda\mathbf{x}\| = |\lambda| \|\mathbf{x}\| = \|\mathbf{B}\mathbf{x}\| \leq \|\mathbf{B}\| \cdot \|\mathbf{x}\|$$

$$|\lambda| \leq \|\mathbf{B}\| \quad \rho(\mathbf{B}) = \max(|\lambda_i|) \leq \|\mathbf{B}\|$$


$$\rho(\mathbf{B}) = \max(\lambda_i) \leq \|\mathbf{B}\|$$

定理4.7 若 $\|\mathbf{B}\| < 1$, 迭代 $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$ 收敛

且有：

$$\|\boldsymbol{\varepsilon}^{(k)}\| \leq \frac{\|\mathbf{B}\|}{1 - \|\mathbf{B}\|} \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|$$

定义4.7 如果矩阵 $A=(a_{ij})_{n \times n}$ 设的元素满足不等式:

$$|a_{ii}| \geq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \quad (i = 1, 2, \dots, n)$$

则矩阵 A 为**对角占优阵**，如果不等式严格成立，称 A 为**严格对角占优**。

定理4.8 若线性方程组 $Ax=b$ 中的 A 为严格对角占优，则Jacobi法和G-S法均收敛。

判断收敛性顺序：


- (1) 充分：A为严格对角占优？是，则收敛。
- (2) 充分： $\|B\| < 1$ ？是，则收敛。
- (3) 充要： $\rho(B) < 1$ ？是，则收敛；不是，则不收敛。

§ 4.3 高斯消去法

n 阶线性方程组

[illegible]

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} \dots & a_{1n} \\ a_{21} & a_{22} \dots & a_{2n} \\ \vdots & \vdots \dots & \vdots \\ a_{n1} & a_{n2} \dots & a_{nn} \end{pmatrix} \quad \mathbf{b} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix} \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

- 
- 1. 消元过程:** 逐渐将系数阵转换为上三角阵;
 - 2. 回代过程:** 逐步回代可得原方程组的解。

§ 4.4 高斯列主消去法

假设Gauss消去法的消元过程进行到第 k ($1 \leq k \leq n-1$) 步, 设

$$a_k = \max_{k \leq i \leq n} |a_{i,k}^{(k)}|$$

并令 i 为达到最大值 a_k 的最小行标 $i \geq k$, 若 $i > k$

则交换 A 和 b 中的第 i 行和第 k 行,
再进行消元过程的第 k 步.

这时每个乘子 $l_{ik} = a_{i,k}^{(k)} / a_{k,k}^{(k)}$ 都满足

$$|l_{i,k}| \leq 1, \quad i = k, \dots, n,$$

可以防止有效数字大量丢失而产生误差.

§ 4.5 三角分解法

Gauss消去法的实质是将矩阵 A 分解为

$$A = L \cdot U$$

其中 L --单位下三角矩阵, U --上三角矩阵.

$$Ax = b \text{ 化为 } Ly = b \quad Ux = y$$

$$\text{消元过程 } y = L^{-1}b, \quad \text{回代过程 } x = U^{-1}y$$

借助矩阵乘法计算!

LU分解公式:

$$\begin{cases} u_{1j} = a_{1j}, & j = 1, 2, \dots, n \\ l_{i1} = \frac{a_{i1}}{u_{11}}, & i = 1, 2, \dots, n \end{cases}$$

对 $k=2, 3, \dots, n$:

$$\begin{cases} u_{kj} = a_{kj} - \sum_{m=1}^{k-1} l_{km} u_{mj}, & j = k, \dots, n \\ u_{ik} = \frac{a_{ik} - \sum_{m=1}^{k-1} l_{im} u_{mk}}{u_{kk}}, & i = k+1, \dots, n \end{cases}$$

基本要求

- 向量范数和矩阵范数的计算；
- 雅克比、高斯-赛德尔迭代矩阵的计算、收敛性判断；
- 高斯消去法、高斯列主元消去法应用；
- 矩阵的三角分解法。

第五章 插值法与最小二乘法

- 5.1 插值法概述
- 5.2 拉格朗日插值法
- 5.3 分段插值法
- 5.4 牛顿插值法
- 5.5 埃尔米特(Hermite)插值
- 5.7 数据拟合的最小二乘法

§ 5.2 拉格朗日 (Lagrange) 插值

§ 5.2.1 Lagrange 插值多项式

$$\text{设 } p_{n+1}(x) = \prod_{i=0}^n (x - x_i), \text{ 有 } p'_{n+1}(x_j) = \prod_{i=0, i \neq j}^n (x_j - x_i)$$

记 n 次多项式:

$$l_j(x) = \frac{(x - x_0)(x - x_1) \dots (x - x_{j-1})(x - x_{j+1}) \dots (x - x_n)}{(x_j - x_0)(x_j - x_1) \dots (x_j - x_{j-1})(x_j - x_{j+1}) \dots (x_j - x_n)}$$

$$l_j(x) = \frac{p_{n+1}(x)}{(x - x_j)p'_{n+1}(x_j)}, \quad j = 0, 1, 2, \dots, n$$

满足插值条件 $y(x_i) = f(x_i)$ 的形如

$y(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$ 的 $Lagrange$ 插值多项式为:

$$y(x) = \sum_{j=0}^n f(x_j)l_j(x), \quad l_j(x) \text{称为插值基函数}$$

被插值函数可表示为:

$$f(x) = \sum_{j=0}^n f(x_j)l_j(x) + E(x)$$

定理5.2 设 $f(x)$ 在 $[a,b]$ 上存在 n 阶连续导数，在 (a,b) 上存在 $n+1$ 阶导数， $y(x)$ 是满足插值条件的Lagrange插值多项式，对任意 $a < x < b$ ，插值余项 **$E(x)$** 为：

$$E(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} p_{n+1}(x)$$

拉格朗日插值公式：

$$y(x) = \sum_{j=0}^n \left[\prod_{\substack{k=0 \\ k \neq j}}^n \frac{x - x_k}{x_j - x_k} \right] f(x_j)$$

§ 5.3 分段插值法

§ 5.3.1 分段线性Lagrange插值

相邻节点分段线性插值：

$$L_h^{(k)}(x) = y_k \frac{x - x_{k+1}}{x_k - x_{k+1}} + y_{k+1} \frac{x - x_k}{x_{k+1} - x_k}$$

§ 5.3.2 分段二次Lagrange插值

$$u \in [x_k, x_{k+1}]$$

当 $|u - x_k| \leq |u - x_{k+1}|$ 时, 取 x_{k-1} , 否则取 x_{k+2}

$$L_h^{(k)}(u) = \sum_{j=k}^{k+2} y_j \left(\prod_{\substack{r=k \\ r \neq j}}^{k+2} \frac{u - x_r}{x_j - x_r} \right)$$

§ 5.4 牛顿插值法

设已知函数 $f(x)$ 在 $n+1$ 个节点 x_0, x_1, \dots, x_n 的函数值,
牛顿插值基函数为:

$$\begin{cases} \varphi_0(x) = 1 \\ \varphi_j(x) = (x - x_0)(x - x_1) \dots (x - x_{j-1}) = \prod_{i=0}^{j-1} (x - x_i) \end{cases}$$

$$p_n(x) = \sum_{j=0}^n a_j \varphi_j(x) = a_0 + \sum_{j=1}^n a_j \prod_{k=0}^{j-1} (x - x_k)$$

$$a_0 = f_0, \quad a_1 = \frac{f_1 - f_0}{x_1 - x_0}, \quad a_2 = \left(\frac{f_2 - f_0}{x_2 - x_0} - \frac{f_1 - f_0}{x_1 - x_0} \right) / (x_2 - x_1)$$

§ 5.4.1 均差(差商)

定义5.1 设 $f(x)$ 在互异的节点 x_0, x_1, \dots, x_n 的函数值为 f_0, f_1, \dots, f_n , 则 $f(x)$ 关于 x_k, x_i 的一阶均差(差商)定义为:

$$f[x_i, x_k] = \frac{f_k - f_i}{x_k - x_i} \quad (k \neq i)$$

二阶均差:

$$f[x_i, x_j, x_k] = \frac{f[x_i, x_k] - f[x_i, x_j]}{x_k - x_j}$$

k阶均差:

$$f[x_0, x_1, \dots, x_{k-1}, x_k] = \frac{f[x_0, x_1, \dots, x_{k-2}, x_k] - f[x_0, x_1, \dots, x_{k-1}]}{x_k - x_{k-1}}$$

数学归纳法可证明:

$$f[x_0, x_1, \dots, x_k] = \sum_{j=0}^k f(x_j) \prod_{\substack{i=0 \\ i \neq j}}^k \frac{1}{x_j - x_i}$$

对称性:

$$f[x_0, \dots, x_i, \dots, x_j, \dots, x_k] = f[x_0, \dots, x_j, \dots, x_i, \dots, x_k]$$

递推计算公式:

$$f[x_0, x_1, \dots, x_k] = \frac{f[x_1, \dots, x_k] - f[x_0, \dots, x_{k-1}]}{x_k - x_0}$$

§ 5.4.2 牛顿插值公式及其余项

由一阶均差定义可得：

$$f(x) = f(x_0) + f[x, x_0](x - x_0)$$

插值多项式：

$$N_n(x) = f(x_0) + \sum_{k=1}^n f[x_0, x_1, \dots, x_k] \prod_{j=0}^{k-1} (x - x_j)$$

§ 5.4.3 差分

定义**5.2** 设 $f(x)$ 在等距节点

$$x_k = x_0 + kh \quad (k = 0, 1, \dots, n)$$

上的函数值为 f_k ，则称

$$\Delta f_k = f_{k+1} - f_k, \nabla f_k = f_k - f_{k-1}$$

分别为一阶向前差分和一阶向后差分。

$$\Delta^m f_k = \Delta^{m-1} f_{k+1} - \Delta^{m-1} f_k, \nabla^m f_k = \nabla^{m-1} f_{k+1} - \nabla^{m-1} f_k$$

为**m**阶向前差分和**m**阶向后差分。

$$\Delta^m f_k = \nabla^m f_{k+m}$$

§ 5.4.4 等节距节点的插值公式

设节点 $x_k = x_0 + kh \quad (k = 0, 1, \dots, n)$

记 $x = x_0 + th \quad (t > 0)$

则 $x - x_k = (t - k)h$

$$f[x_0, x_1, \dots, x_k] \prod_{j=0}^{k-1} (x - x_j) = \frac{\Delta^k f_0}{k! h^k} t(t-1)\dots(t-k+1)h^k$$

$$= \frac{\Delta^k f_0}{k!} \prod_{j=0}^{k-1} (t - j)$$

牛顿向前插值公式:

$$N_n(x_0 + th) = f_0 + \sum_{k=1}^n \frac{\Delta^k f_0}{k!} \prod_{j=0}^{k-1} (t - j)$$

设 $x_{n-k} = x_n - kh \quad (k = 0, 1, \dots, n)$

$$x = x_n + th \quad (t < 0)$$

则 $x - x_{n-k} = (t + k)h$

牛顿向后插值公式:

$$N_n(x_0 + th) = f_n + \sum_{k=1}^n \frac{\nabla^k f_n}{k!} \prod_{j=0}^{k-1} (t + j)$$

§ 5.5 埃尔米特(Hermite)插值

构造插值多项式 $H(x)$ ，不仅要求在某些节点上函数值相等，还要求一阶导数甚至高阶导数值相等。

$$f(x_1), f'(x_1), \dots, f^{(m_1)}(x_1);$$

$$f(x_2), f'(x_2), \dots, f^{(m_2)}(x_2);$$

.....

$$f(x_n), f'(x_n), \dots, f^{(m_n)}(x_n).$$

$$N = \sum_{i=1}^n m_i + n$$

寻找一个次数 $\leq N-1$ 的多项式 $H(x)$ ，满足：

$$f(x_i) = H(x_i) \quad (i = 0, 1, \dots, n)$$

$$f'(x_i) = H'(x_i)$$

$$f^{(m_i)}(x_i) = H^{(m_i)}(x_i)$$

§ 5.7 数据拟合的最小二乘法




图 5-11 某物体的直线运动数据在坐标平面

$$S(t) = at + b$$

$$\text{记: } \delta_i = S(t_i) - s_i$$

最小化:

$$\|\delta\|_2^2 = \sum_{i=0}^m \omega_i \delta_i^2 = \sum_{i=0}^m \omega_i (S(t_i) - s_i)^2$$

推广至一般情形：

$$\Phi = \text{span}\{\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)\}$$

求：

$$S^*(x) = \sum_{j=0}^n a_j^* \varphi_j(x) \quad (n \leq m)$$

满足：

$$\|\delta\|_2^2 = \sum_{i=0}^m \omega_i (S^*(x_i) - y_i)^2 = \min_{S \in \Phi} \sum_{i=0}^m \omega_i (S(x_i) - y_i)^2$$

数据拟合的**最小二乘法**。

§ 5.7.1 法方程组

记:

$$\Psi(a_0, a_1, \dots, a_n) = \sum_{i=0}^m \omega_i (S(x_i) - y_i)^2 = \sum_{i=0}^m \omega_i \left(\sum_{j=0}^n a_j \varphi_j(x_i) - y_i \right)^2$$

由 $\frac{\partial \Psi}{\partial a_k} = 0 (k = 0, 1, \dots, n)$

得: $\sum_{i=0}^m \omega_i \left(\sum_{j=0}^n a_j \varphi_j(x_i) - y_i \right) \varphi_k(x_i) = 0$

即: $\sum_{j=0}^n \left(\sum_{i=0}^m \omega_i \varphi_j(x_i) \varphi_k(x_i) \right) a_j = \sum_{i=0}^m \omega_i y_i \varphi_k(x_i)$

令: $\varphi_r = (\varphi_r(x_0), \varphi_r(x_1), \dots, \varphi_r(x_m)) \quad (r = 0, 1, \dots, n)$
 $f = (y_0, y_1, \dots, y_m)$

定义内积:

$$(\varphi_j, \varphi_k) = \sum_{i=0}^m \omega_i \varphi_j(x_i) \varphi_k(x_i) \quad (f, \varphi_k) = \sum_{i=0}^m \omega_i y_i \varphi_k(x_i)$$

有:
$$\sum_{j=0}^m (\varphi_j, \varphi_k) a_j = (f, \varphi_k) \quad (k = 0, 1, \dots, n)$$

称为函数系在离散点上的**法方程**。

$$\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \dots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \dots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \dots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \dots & (\varphi_n, \varphi_n) \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ \vdots \\ (f, \varphi_n) \end{pmatrix}$$

基本要求

- 拉格朗日插值法计算；
- 一次和二次分段拉格朗日插值法计算；
- 差商的计算，牛顿插值法计算；
- 埃尔米特插值基本概念；
- 最小二乘法数据拟合的法方程组方法。

第六章 数值微分与积分

- 6.1 数值微分
- 6.2 牛顿-柯特斯求积公式
- 6.3 复合求积法
- 6.4 龙贝格求积法
- 6.5 高斯求积公式

§ 6.1 数值微分

§ 6.1.1 差商公式

$$f'(a) = \lim_{h \rightarrow 0} \frac{f(a+h) - f(a)}{h}$$

近似为：

向前差商：

$$f'(a) \approx \frac{f(a+h) - f(a)}{h}$$

向后差商：

$$f'(a) \approx \frac{f(a) - f(a-h)}{h}$$

中心差商：

$$f'(a) \approx \frac{f(a+h) - f(a-h)}{2h}$$

§ 6.1.2 中点方法的加速

$$G(h) = f'(a) + a_1 h^2 + a_2 h^4 + a_3 h^6 + \dots$$

$$G\left(\frac{h}{2}\right) = f'(a) + \frac{a_1}{4} h^2 + \hat{a}_2 h^4 + \hat{a}_3 h^6 + \dots$$

$$G_1(h) = \frac{4}{3} G\left(\frac{h}{2}\right) - \frac{1}{3} G(h)$$

$$G_1(h) = f'(a) + \beta_1 h^4 + \beta_2 h^6 + \dots$$

进一步，令：

$$G_2(h) = \frac{16}{15} G_1\left(\frac{h}{2}\right) - \frac{1}{15} G_1(h)$$

$$G_2(h) = f'(a) + \gamma h^6 + \dots$$

$$G_3(h) = \frac{64}{63} G_2\left(\frac{h}{2}\right) - \frac{1}{63} G_2(h)$$

§ 6.1.3 插值型的求导公式

利用 $f(x)$ 在 x_k ($k = 0, 1, \dots, n$)处的函数值, 求 n 次插值多项式 $p_n(x)$, 计算导数作为近似:

$$f'(x) \approx p'_n(x)$$

$$f'(x_0) \approx \frac{1}{2h}[-3f(x_0) + 4f(x_1) - f(x_2)]$$

$$f'(x_1) \approx \frac{1}{2h}[-f(x_0) + f(x_2)]$$

$$f'(x_2) \approx \frac{1}{2h}[f(x_0) - 4f(x_1) + 3f(x_2)]$$

§ 6.2 牛顿-柯特斯求积公式

§ 6.2.1 插值型求积公式及Cotes系数

设 $f(x) \in C[a, b]$, 求定积分 $I = \int_a^b f(x) dx$ 的近似值。

将 $[a, b]$ n 等分, 步长为 $h = (b-a)/n$ 。取节点:

$$x_k = a + kh \quad (k = 0, 1, \dots, n)$$

f(x)可表示为**Lagrange**插值多项式及其余项之和:

$$f(x) = \sum_{k=0}^n f(x_k) l_k(x) + R_n(x)$$

$$I = \int_a^b f(x)dx = \sum_{k=0}^n \left(\int_a^b l_k(x)dx \right) f(x_k) + \int_a^b R_n(x)dx$$

$$= \sum_{k=0}^n A_k f(x_k) + \int_a^b R_n(x)dx$$

其中 $A_k = \int_a^b \left(\prod_{j=0, j \neq k}^n \frac{x - x_j}{x_k - x_j} \right) dx$

$$C_k^{(n)} = \frac{(-1)^{n-k}}{n \cdot k!(n-k)!} \int_0^n \prod_{j=0, j \neq k}^n (t-j) dt$$

$$I_n = (b-a) \sum_{k=0}^n C_k^{(n)} f(x_k)$$

在**Newton-Cotes**公式中，最重要的是**n=1、2、4**时的**3**个公式。

梯形公式：

$$T = I_1 = \frac{b-a}{2} [f(a) + f(b)]$$

Simpson公式：

$$S = I_2 = \frac{b-a}{6} [f(a) + 4f(\frac{a+b}{2}) + f(b)]$$

Cotes公式：

$$C = I_4 = \frac{b-a}{90} [7f(a) + 32f(x_1) + 12f(x_2) + 32f(x_3) + 7f(b)]$$

定义6.1 如果某个求积公式，对于任何次数不超过 m 的代数多项式都能准确成立，但对于 $m+1$ 次代数多项式不能准确成立，则称该求积公式具有 **m 次代数精度**。

梯形公式、**Simpson**公式、**Cotes**公式的代数精度分别为**1**阶、**3**阶和**5**阶。

§ 6.3 复合求积法

§ 6.3.1 复合求积公式

将 $[a,b]$ 等分成 n 个子区间，在每个区间上使用低阶求积公式进行计算，然后求和。

分区间利用梯形公式：

$$\int_{x_k}^{x_{k+1}} f(x)dx \approx \frac{h}{2}[f(x_k) + f(x_{k+1})]$$

$$\begin{aligned}\int_a^b f(x)dx &= \sum_{k=0}^{n-1} \int_{x_k}^{x_{k+1}} f(x)dx \approx \sum_{k=0}^{n-1} \frac{h}{2}[f(x_k) + f(x_{k+1})] \\ &= \frac{h}{2}[f(a) + 2\sum_{k=1}^{n-1} f(x_k) + f(b)] = \frac{b-a}{2n}[f(a) + 2\sum_{k=1}^{n-1} f(x_k) + f(b)]\end{aligned}$$

复合梯形公式:

$$T_n = \frac{b-a}{2n} \left[f(a) + 2 \sum_{k=1}^{n-1} f(x_k) + f(b) \right]$$

复合**Simpson**公式:

$$S_n = \frac{b-a}{6n} \left[f(a) + 4 \sum_{k=0}^{n-1} f(x_{k+1/2}) + 2 \sum_{k=1}^{n-1} f(x_k) + f(b) \right]$$

复合**Cotes**公式:

$$S_n = \frac{b-a}{90n} \left[7f(a) + 32 \sum_{k=0}^{n-1} f(x_{k+1/4}) + 12 \sum_{k=1}^{n-1} f(x_{k+1/2}) \right. \\ \left. + 32 \sum_{k=0}^{n-1} f(x_{k+3/4}) + 14 \sum_{k=1}^{n-1} f(x_k) + 7f(b) \right]$$

§ 6.3.2 复合求积公式的余项与收敛的阶

复合梯形公式余项:

$$I - T_n \approx -\frac{h^2}{12}[f'(b) - f'(a)]$$

复合**Simpson**公式余项:

$$I - S_n \approx -\frac{1}{180}\left(\frac{h}{2}\right)^4[f'''(b) - f'''(a)]$$

定义**6.2** 如果一种复合求积公式 **I_n** ，当 **$h \rightarrow 0$** 时，有

$$\lim_{h \rightarrow 0} \frac{I - I_n}{h^P} = c \quad (c \neq 0)$$

则称求积公式 **I_n** 是 **$P(\geq 1)$** 阶收敛的。

T_n 、 **S_n** 、 **C_n** 分别是**2**、**4**、**6**阶收敛。

§ 6.3.3 步长的自动选择

- 计算精度与步长有关;
- 高阶导数不易求, 根据余项估计不可行。
- 通过计算自动选择:

$$I - T_{2n} \approx -\frac{1}{12} \left(\frac{h}{2} \right)^2 [f'(b) - f'(a)]$$

$$\frac{I - T_{2n}}{I - T_n} \approx \frac{1}{4} \quad I - T_{2n} \approx \frac{1}{3} (T_{2n} - T_n)$$

以 T_{2n} 为近似, 截断误差绝对值约为 $\Delta \approx \frac{1}{3} |T_{2n} - T_n|$

令 $h = b - a$, 计算 T_1 ;

步长折半, 计算 T_2 及 $\Delta = \frac{1}{3} |T_2 - T_1|$;

反复计算, 直到误差满足要求 $\Delta \leq \varepsilon$

Simpson 公式:

$$I - S_{2n} \approx \frac{1}{15} (S_{2n} - S_n), \Delta = \frac{1}{15} |S_{2n} - S_n|$$

Cotes 公式:

$$I - C_{2n} \approx \frac{1}{63} (C_{2n} - C_n), \Delta = \frac{1}{63} |C_{2n} - C_n|$$

§ 6.4 龙贝格(Romberg)求积法

§ 6.4.1 梯形法的递推化

$$T_n = \frac{h}{2} [f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b)]$$

步长折半, 增加节点 $x_{i+1/2} = \frac{1}{2}(x_i + x_{i+1})$,

在 $[x_i, x_{i+1}]$ 积分为 $\frac{h}{4} [f(x_i) + 2f(x_{i+1/2}) + f(x_{i+1})]$

$$\begin{aligned} T_{2n} &= \frac{h}{4} \sum_{i=0}^{n-1} [f(x_i) + 2 \sum_{i=1}^{n-1} f(x_{i+1/2}) + f(x_{i+1})] \\ &= \frac{h}{4} \sum_{i=0}^n [f(x_i) + f(x_{i+1})] + \frac{h}{2} \sum_{i=0}^{n-1} f(x_{i+1/2}) \end{aligned}$$

$$T_{2n} = \frac{1}{2} T_n + \frac{h}{2} \sum_{i=0}^{n-1} f(x_{i+1/2})$$

§ 6.4.2 龙贝格求积法

$$\text{由: } I - T_{2n} \approx \frac{1}{3}(T_{2n} - T_n)$$

$$\text{得: } \bar{T} = T_{2n} + \frac{1}{3}(T_{2n} - T_n) = \frac{4}{4-1}T_{2n} - \frac{1}{4-1}T_n$$

$$\text{即Simpson公式: } S_n = \frac{4}{4-1}T_{2n} - \frac{1}{4-1}T_n$$

由Simpson公式:

$$I \approx S_{2n} + \frac{1}{4^2-1}(S_{2n} - S_n) = \frac{4^2}{4^2-1}S_{2n} - \frac{1}{4^2-1}S_n$$

$$\text{即Cotes公式: } C_n = \frac{4^2}{4^2-1}S_{2n} - \frac{1}{4^2-1}S_n$$

由Cotes公式得Romberg公式: $R_n = \frac{4^3}{4^3 - 1} C_{2n} - \frac{1}{4^3 - 1} C_n$

继续下去, 以 $T_0^{(k)}$ 表示二分 k 次后的梯形值,

$T_m^{(k)}$ 表示序列 $\{T_0^{(k)}\}$ 的 m 次线性组合, 得:

$$T_m^{(k)} = \frac{4^m}{4^m - 1} T_{m-1}^{(k+1)} - \frac{1}{4^m - 1} T_{m-1}^{(k)} = T_{m-1}^{(k+1)} + \frac{1}{4^m - 1} (T_{m-1}^{(k+1)} - T_{m-1}^{(k)})$$

$$K=0,1,2,\dots; m=1,2,3,\dots$$
表 6-4 $T_m^{(k)}$ 三角形表[illegible]

Romberg求积算法:

$$(1) T_0^{(0)} = \frac{b-a}{2} [f(a) + f(b)], \quad k = 1$$

$$(2) T_0^{(k)} = \frac{1}{2} T_0^{(k-1)} - \frac{b-a}{2^k} \sum_{i=0}^{2^{k-1}} f[a + (2i-1) \frac{b-a}{2^k}]$$

$$(3) T_i^{(k-i)} = \frac{4^i T_{i-1}^{(k-i+1)} - T_{i-1}^{(k-i)}}{4^i - 1}, \quad i = 1, 2, \dots, k$$

(4) 若 $|T_k^{(0)} - T_{k-1}^{(0)}| < \varepsilon$, 则输出 $T_k^{(0)}$; 否则 $k = k + 1$ 返回(2)。

§ 6.5 高斯求积公式

考虑如下带权求积公式：

$$I = \int_a^b \rho(x) f(x) dx \approx \sum_{i=0}^n w_i f(x_i)$$

当积分具有**2n+1**次代数精度时，插值点称为**高斯点**。

先考虑 $\rho(x) \equiv 1$ 的特殊情况：

定理6.1 高斯求积公式中节点 $x_i (i = 0, 1, 2, \dots, n)$ 是高斯点

的充要条件是这些点为零点的多项式 $\omega(x) = \prod_{i=0}^n (x - x_i)$

与任意不超过 n 的多项式 $p(x)$ 均正交，即 $\int_a^b p(x) \omega(x) dx = 0$

基本要求

- 数值微分，差商近似导数的计算；
- 梯形、Simpson求积公式；
- 梯形、Simpson复合求积法；
- 龙贝格积分法和高斯求积公式的基本思想。

第七章 常微分方程的数值解法

- 7.1 欧拉(Euler)法
- 7.2 改进的欧拉法
- 7.3 龙格-库塔(Runge-Kutta)法
- 7.4 线性多步法

引言

一阶常微分方程的初值问题:

$$\begin{cases} \frac{dy}{dx} = f(x, y) & a \leq x \leq b \\ y(a) = y_0 \end{cases}$$

假设函数 $f(x, y)$ 连续, 且满足**Lipschitz**条件:

$$|f(x, y) - f(x, \bar{y})| \leq L |y - \bar{y}|$$

§ 7.1 欧拉(Euler)法

§ 7.1.1 Euler方法公式

$$\begin{cases} y_{n+1} = y_n + hf(x_n, y_n) & (n = 0, 1, \dots) \\ y_0 = y(a) \end{cases}$$

向后差商隐式迭代法:

$$\begin{cases} y_{n+1} = y_n + hf(x_{n+1}, y_{n+1}) & (n = 0, 1, \dots) \\ y_0 = y(a) \end{cases}$$

$$\begin{cases} y_{n+1}^{(0)} = y_n + hf(x_n, y_n) \\ y_{n+1}^{(k+1)} = y_n + hf(x_{n+1}, y_{n+1}^{(k)}) & (k = 0, 1, \dots) \end{cases}$$

§ 7.1.2 Euler方法的估计误差

定义**7.1** 单步法的局部截断误差:

$$R_{n+1} = y(x_{n+1}) - y(x_n) - h\varphi(x_n, y_n, x_{n+1}, y(x_{n+1}), h)$$

Euler法泰勒展开式估计:

$$\begin{aligned} R_{n+1} &= y(x_{n+1}) - y(x_n) - hf(x_n, y(x_n)) \\ &= y(x_n + h) - y(x_n) - hy'(x_n) = \frac{1}{2}h^2 y''(\xi) \end{aligned}$$

$$R_{n+1} = \frac{1}{2}h^2 y''(x_n) + O(h^3) = O(h^2)$$

局部截断误差为 $O(h^{p+1})$ ，则称该方法是 p 阶的。

§ 7.2 改进的欧拉法

§ 7.1.1 梯形公式

$$\int_{x_n}^{x_{n+1}} f(x, y(x)) \approx \frac{h}{2} [f(x_n, y(x_n)) + f(x_{n+1}, y(x_{n+1}))]$$

$$y_{n+1} = y_n + \frac{h}{2} [f(x_n, y_n) + f(x_{n+1}, y_{n+1})]$$

$$\begin{aligned} R_{n+1} &= y(x_{n+1}) - y(x_n) - \frac{h}{2} [f(x_n, y_n) + f(x_{n+1}, y(x_{n+1}))] \\ &= -\frac{h^3}{12} y'''(\xi) \quad (x_n < \xi < x_{n+1}) \end{aligned}$$

梯形公式为二阶方法，属隐式格式，一般用迭代法求解。

§ 7.2.2 改进Euler法

在梯形公式中，隐式公式的求解只迭代一次：

$$\begin{cases} \bar{y}_{n+1} = y_n + hf(x_n, y_n) & \text{预测} \\ y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, \bar{y}_{n+1})] & \text{校正} \end{cases}$$

为编程方便，改写为：

$$\begin{cases} y_p = y_n + hf(x_n, y_n) \\ y_q = y_n + hf(x_n + h, y_p) \\ y_{n+1} = (y_p + y_q) / 2 \end{cases}$$

§ 7.3 龙格-库塔(Runge-Kutta)法

§ 7.3.1 龙格-库塔法基本思想

(1) Euler公式:

$$\begin{cases} y_{n+1} = y_n + hK_1 \\ K_1 = f(x_n, y_n) \end{cases}$$

(2) 改进的Euler公式:

$$\begin{cases} y_{n+1} = y_n + h(K_1 + K_2)/2 \\ K_1 = f(x_n, y_n) \\ K_2 = f(x_n + h, y_n + hK_1) \end{cases}$$

利用函数 $f(x, y)$ 在某些点上的线性组合来计算 $y(x_{n+1})$ 的近似值 y_{n+1} 。

可利用近似Taylor展开式的更多项来增加精度。

$$y_{n+1} = y_n + hy'(x_n) + \frac{h^2}{2!} y''(x_n) + \dots + \frac{h^p}{p!} y^{(p)}(x_n)$$

§ 7.3.2 龙格-库塔法的构造

算法 7.1

$$\begin{cases} y_{n+1} = y_n + \sum_{i=1}^p c_i K_i \\ K_1 = f(x_n, y_n) \\ K_i = f(x_n + a_i h, y_n + h \sum_{j=1}^{i-1} b_{ij} K_j) \end{cases}$$

参数确定原则：其Taylor展开式与 $y(x)$ 在 x_n 尽可能多项重合。

§ 7.3.3 变步长的龙格-库塔法

$y(x)$ 变化可能不均匀，等步长求解可能有些地方精度过高，有些地方精度过低。

如何根据精度自动调节步长？

$$\left| y(x_{n+1}) - y_{n+1}^{(h)} \right| \approx \frac{2^p}{(2^p - 1)} \left| y_{n+1}^{(h)} - y_{n+1}^{(h/2)} \right| \approx \Delta$$

缩小或放大**h**直到达到要求计算精度。

§ 7.4 线性多步法

单步法在计算 y_{n+1} 时仅利用了 y_n ，多步法利用 y_n ， y_{n-1} ， y_{n-2} ，...

一般形式：

$$y_{n+1} = \sum_{i=0}^r a_i y_{n-i} + \sum_{i=-1}^r \beta_i f_{n-i}$$

若 $\beta_{-1}=0$ ，显式；若 $\beta_{-1} \neq 0$ ，隐式。

基本要求

- 欧拉法；
- 改进的欧拉法；
- 龙格-库塔法及线性多步法的基本思想。

考试时间：2015.6.25

考试地点	人数	教学班
逸105	109	计1301[1],计1303[35],计1202[1],计1304[33],电信13[30],重修[8],信安1102[1]
逸204	99	计1302[34],计1303[2],计1301[37],信安1102[1],计1204[1],计1201[2],电信12[1],重修[12],信安1202[4],信安1201[5]